

DOCUMENTACIÓN DE MODELADO DE DATOS

Proyecto Final — Visualización y Storytelling
Vulnerabilidad y Patrones de Emergencias en Colombia (1998–2024)

1. Resumen Ejecutivo

Este documento describe el proceso completo de construcción, limpieza, integración y modelado del dataset utilizado para el análisis de vulnerabilidad y severidad de eventos de inundación en Colombia durante el período 1998–2024.

El dataset final es el resultado de la integración de seis fuentes públicas del Estado colombiano:

- 1. Registros de emergencias – UNGRD
- 2. Series de precipitación – IDEAM
- 3. Series de temperatura – IDEAM
- 4. Series de presión atmosférica – IDEAM
- 5. Tabla de codificación territorial – DIVIPOLA (DANE)
- 6. Geometrías municipales – IGAC/DANE

El proceso implicó resolver inconsistencias estructurales, problemas de calidad textual, cambios longitudinales en los reportes institucionales y ausencia parcial de codificación territorial.

El dataset modelado final contiene:

- 17.828 registros
- 45 columnas
- 27 años de cobertura
- Codificación territorial validada
- Variables derivadas para análisis temporal
- Estructura compatible con análisis geoespacial

2. Fuentes de Datos Iniciales

Fuente	Productor	Años disponibles	Volumen aproximado	Rol en el proyecto
UNGRD Emergencias	UNGRD	1998–2024	72.807 registros	Base estructural del análisis
IDEAM Precipitación	IDEAM	2003–2026	~270M	Contexto hidrometeorológico
IDEAM Temperatura	IDEAM	2001–2026	~88,7M	Contexto climático

IDEAM Presión	IDEAM	2001–2026	~32,4M	Contexto atmosférico
DIVIPOLA	DANE	Vigente	Catálogo	Integridad territorial
GeoJSON	IGAC/DANE	2026	1.121 polígonos	Cartografía

2.1 Dataset de Emergencias – UNGRD

Productor: Unidad Nacional para la Gestión del Riesgo de Desastres

Cobertura: 1 enero 1998 – 31 diciembre 2024

Granularidad: Evento por municipio

Formato original: 27 archivos anuales .xls

Registros consolidados iniciales: 72.807 × 45 columnas

Contenido:

- Tipo de evento (36+ categorías)
- Afectación humana
- Daños a infraestructura
- Ayudas humanitarias
- Recursos ejecutados
- Estado del trámite

Problemas identificados:

- Archivos con macros internas
- Algunos protegidos con contraseña
- Variación estructural entre años
- Cambios en columnas de recursos desde 2023
- Ausencia frecuente del código DIVIPOLA antes de 2018
- Variaciones ortográficas en municipios
- No existen coordenadas GPS por evento

2.2 Dataset de Precipitación – IDEAM

Cobertura: Enero 2003 – presente

Granularidad: 5–10 minutos por sensor

Volumen: ~270 millones de registros

Estructura: 12 columnas

Variables comunes:

- CodigoEstacion
- CodigoSensor
- FechaObservacion
- ValorObservado
- Latitud

- Longitud
- Departamento
- Municipio
- ZonaHidrografica
- UnidadMedida

Uso en el proyecto:

Referencia para contextualización hidrometeorológica.

2.3 Dataset de Temperatura – IDEAM

Cobertura: Enero 2001 – presente

Volumen: ~88,7 millones de registros

Estructura idéntica a precipitación.

2.4 Dataset de Presión Atmosférica – IDEAM

Cobertura: Marzo 2001 – presente

Volumen: ~32,4 millones de registros

2.5 DIVIPOLA – DANE

DIVIPOLA es el estándar oficial de codificación territorial administrado por el DANE desde 1953, que garantiza unicidad y estabilidad en la identificación municipal.

- Código departamento (2 dígitos)
- Código municipio (3 dígitos)
- Código concatenado (5 dígitos)
- Nombre oficial municipio

Uso crítico:

- Validación territorial
- Join con GeoJSON
- Consistencia longitudinal

2.6 GeoJSON Municipios y Veredas

Formato: GeoJSON

Municipios: 1.121

Propiedad clave: DPTOMPIO (5 dígitos)

Join recomendado:

DIVIPOLA (CSV) ↔ DPTOMPIO (GeoJSON)

3. Proceso de Construcción del Dataset Consolidado

3.1 Conversión Segura de Archivos XLS

- Apertura en entorno controlado
- Exportación manual sin ejecución de macros
- Conversión a CSV intermedio

3.2 Mapeo Estructural por Año

Dado que los encabezados cambiaban entre periodos:

- Se realizó mapeo por índice posicional
- Se identificaron columnas conceptualmente equivalentes
- Se unificaron denominaciones

Resultado:

72.807 registros × 45 columnas (todos los tipos de emergencias)

3.3 Normalización Territorial

Procedimiento:

1. Conversión a mayúsculas
2. Eliminación de espacios extra
3. Corrección de tildes
4. Homologación con catálogo oficial DANE
5. Asignación programática de código DIVIPOLA faltante

Ejemplo:

Santa fe de Bogota → BOGOTÁ

Decisión técnica:

DIVIPOLA se trató como texto para preservar ceros a la izquierda.

3.4 Limpieza General

- Eliminación de columna RUD (99.9% nula)
- Eliminación de COMENTARIOS (texto libre no estructurado)
- Eliminación de 80 duplicados
- Normalización de columna multilínea HORAS MAQUINA
- Corrección de valores inconsistentes

3.5 Cambio Estructural 2023–2024

Desde 2023:

- UNGRD desagrega ayudas por ítem físico
- Columnas tradicionales quedan vacías

- Única variable financiera consistente: RECURSOS EJECUTADOS

Se documenta explícitamente este cambio longitudinal.

3.6 Evaluación de Calidad de Datos

Integridad referencial: 100% de los códigos DIVIPOLA presentes en el dataset final son compatibles con la tabla oficial del DANE y con el GeoJSON municipal.

- **Compleitud:** Variables como PERSONAS (71%) vs MUERTOS (5.4%).
- **Consistencia territorial:** 98% de registros con DIVIPOLA validado.
- **Unicidad:** Eliminación de 80 duplicados.
- **Integridad**

4. Filtrado Temático – Eventos de Riesgo Hídrico

De los 72.807 registros iniciales se seleccionaron:

EVENTO	REGISTROS
INUNDACION	15.434
CRECIENTE SUBITA	1.427
TEMPORAL	484
AVENIDA TORRENCIAL	483

- 72.807 registros → emergencias totales.
- 52.1K → consolidado tras limpieza estructural.
- 17.828 → subconjunto filtrado por riesgo hídrico
- Se unificaron variantes ortográficas antes del filtrado.

5. Estructura Final del Dataset Modelado

Formato:

- CSV
- Separador ;
- Encoding UTF-8 con BOM
- 17.828 filas × 45 columnas

Variable	Tipo	Descripción
FECHA	datetime	Fecha del evento reportado por la UNGRD.
DEPARTAMENTO	texto	Departamento donde ocurrió el evento.
MUNICIPIO	texto	Municipio donde ocurrió el evento.
EVENTO	texto	Tipo de fenómeno natural o antrópico no intencional.
CODIFICACIÓN DIVIPOLA	texto/numérico	Código municipal reportado en la base original.
MUERTOS	numérico entero	Número de víctimas mortales.
HERIDOS	numérico entero	Número de personas heridas.
DESAPA.	numérico entero	Número de personas desaparecidas.
PERSONAS	numérico entero	Total de personas afectadas.
FAMILIAS	numérico entero	Total de familias afectadas.
VIV.DESTRU.	numérico entero	Viviendas destruidas.
VIV.AVER.	numérico entero	Viviendas averiadas.
VIAS	numérico entero	Vías afectadas.
PTES.VEHIC.	numérico entero	Puentes vehiculares dañados.
PTES.PEAT.	numérico entero	Puentes peatonales dañados.
ACUED.	numérico entero	Acueductos afectados.
ALCANT.	numérico entero	Alcantarillados afectados.
C. SALUD	numérico entero	Centros de salud afectados.
C.EDUCAT.	numérico entero	Centros educativos afectados.
C.COMUNIT.	numérico entero	Centros comunitarios afectados.

HECTAREAS	numérico	Hectáreas afectadas.
RECURSOS EJECUTADOS	numérico	Valor total de recursos ejecutados.
TRAMITE ANTE UNGRD	texto	Estado del trámite ante la UNGRD.
ATENDIDO	texto	Indica si el evento fue atendido.
DIVIPOLA	texto	Código municipal corregido según DANE.
AÑO	numérico entero	Año derivado de la fecha del evento.
MES	numérico entero	Mes derivado de la fecha del evento.

6. Procedimiento Paso a Paso Replicable

1. Descargar 27 archivos anuales UNGRD.
 2. Exportar a CSV sin macros.
 3. Unificar estructura.
 4. Normalizar texto territorial.
 5. Cruce con DIVIPOLA.csv.
 6. Asignar código validado.
 7. Eliminar columnas vacías.
 8. Crear variables AÑO y MES.
 9. Eliminar duplicados.
 10. Filtrar eventos hídricos.
1. Exportar CSV final con separador “;” y UTF-8 BOM.

Código de carga recomendado:

```
import pandas as pd

df = pd.read_csv(
    'CONSOLIDADO_EMERGENCIAS_1998-2024.csv',
    sep=';',
    encoding='utf-8-sig',
    dtype={'DIVIPOLA': str,
          'CODIFICACIÓN SEGUN DIVIPOLA': str},
    low_memory=False
)
```

7. Coherencia entre Modelado y Visualización

El modelado fue diseñado explícitamente para soportar:

- Mapas coropléticos → DIVIPOLA
- Tendencias temporales → AÑO
- Estacionalidad → MES
- Comparaciones de severidad → PERSONAS, MUERTOS
- Daño físico → VIV.DESTRU., HECTAREAS

No se realizaron imputaciones para evitar sesgos interpretativos.

8. Limitaciones

- Posible subregistro histórico.
- No existen coordenadas por evento.
- Datos IDEAM no validados oficialmente.
- Dependencia de reporte institucional.
- Cambio de esquema FNGRD 2023.
- No imputación de valores faltantes.

9. Conclusión Técnica

El dataset cumple criterios de consistencia estructural, integridad territorial, trazabilidad longitudinal y replicabilidad técnica, lo que lo hace apto para análisis descriptivo, comparativo y cartográfico en contextos académicos y de política pública.

- Integra 27 años de información pública.
- Garantiza consistencia territorial.
- Documenta cambios estructurales longitudinales.
- Es replicable.

- Está alineado con la narrativa del proyecto.
- Permite análisis temporal, territorial y descriptivo de severidad.